

Week 3: SVM 算法基本原理

滕明卓

2021 年 4 月 2 日

1 SVM 基础思想

间隔最大化。

2 优化问题 (原问题)

从简单的二类线性可分的情况下, 推导出 SVM 的优化问题形式。

点 \mathbf{x}_i 到超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的距离为

$$\frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|}$$

同时缩放 w 和 b , 不改变这个距离。

假设超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 可将数据样本分开。即对于正类样本 (标记 $y = +1$) 和负类样本 (标记 $y = -1$), 有

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b > 0, y_i = 1 \\ \mathbf{w}^T \mathbf{x}_i + b < 0, y_i = -1 \end{cases} \quad (1)$$

同时缩放 w 和 b , 使得

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b \geq 1, y_i = 1 \\ \mathbf{w}^T \mathbf{x}_i + b \leq -1, y_i = -1 \end{cases} \quad (2)$$

这样, 正负样本点到超平面的距离之和就是 $\frac{2}{\|\mathbf{w}\|}$, 这个距离被称为”间隔”。

因此得到优化问题:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m. \end{aligned} \quad (3)$$

转化为等价形式:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m. \end{aligned} \quad (4)$$

这个优化问题就是 SVM 的原问题，这是一个凸优化问题。

3 对偶

使用拉格朗日乘子法得到 SVM 的对偶问题。原问题满足 slater 条件，满足强对偶性，即对偶问题的最优值与原问题最优质相等。因此可以通过求解对偶问题来找到最优值，求最优解。

拉格朗日函数:

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

令其对优化变量 \mathbf{w}, b 求导等于 0，得:

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0$$

回代到拉格朗日函数中，消除 \mathbf{w}, b ，得到对偶问题:

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, m. \end{aligned} \quad (5)$$

需满足 KKT 条件:

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(\mathbf{x}_i) \geq 1 \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0 \\ \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \\ \sum_{i=1}^m \alpha_i y_i = 0 \end{cases} \quad (6)$$

KKT 条件其中第三条被称为互补松弛性, 如果拉格朗日乘子 α_i 不为 0, 那么必有 $y_i f(\mathbf{x}_i) = 1$, 也就是这个样本点在间隔的边界上。这些样本被称为“支持向量”。

4 SVM 算法过程

- 输入: 线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$, 其中, $x_i \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, m$
- 输出: 最大间隔分离超平面和分类决策函数.

1. 构建并求解约束最优化问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, m \end{aligned} \quad (7)$$

求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_m^*)^T$

2. 计算

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i \quad (8)$$

选择 α^* 的一个分量 $\alpha_j^* > 0$, 计算

$$b^* = y_j - \mathbf{w}^{*\top} \mathbf{x}_j \quad (9)$$

现实任务中常采用一种更鲁棒的做法: 使用所有支持向量求解平均值。

3. 得到分离超平面

$$\mathbf{w}^{*\top} \mathbf{x} + b^* = 0 \quad (10)$$

分类决策函数

$$f(x) = \text{sign}(\mathbf{w}^{*\top} \mathbf{x} + b^*) \quad (11)$$

5 SMO 算法求解对偶问题

1. 选取一对需要更新的变量 α_i, α_j
2. 固定 α_i, α_j 以外的参数, 求解对偶问题, 更新 α_i, α_j

仅考虑 α_i 和 α_j 时对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0$$

用一个变量表示另一个变量, 回代入对偶问题可得一个单变量的二次规划, 该问题具有闭式解.

6 线性到非线性-核技巧

一些分类问题无法用线性超平面划分, 比如异或问题。如何解决? 将样本从原始空间映射到更高维的特征空间, 使得样本在这个特征空间内线性可分。

$$\mathbf{x} \rightarrow \phi(\mathbf{x})$$

模型表示为

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$$

按之前的思路, 得到对偶问题:

$$\begin{aligned} \min_{\alpha} & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, m. \end{aligned} \quad (12)$$

有时计算 $\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$ 是很困难的, 甚至不存在显式的映射。

使用核函数

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

来代替 $\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$

Mercer 定理：只要一个对称函数所对应的它就能作核矩阵半正定, 为核函数来使用

对偶问题重写为：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, m. \end{aligned} \tag{13}$$

预测：

$$\begin{aligned} f(\mathbf{x}) &= \mathbf{w}^\top \phi(\mathbf{x}) + b \\ &= \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}) + b \\ &= \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}, \mathbf{x}_i) + b \end{aligned} \tag{14}$$

常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$

(15)

7 不可分-软间隔

7.1 原始问题

允许支持向量机在一些样本上出错，采用惩罚项的方式来放松约束。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1}(y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

采用 hinge loss

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

令 $\xi_i = \max(0, 1 - y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$

则优化问题等价于：

$$\begin{aligned} \min_{\mathbf{w}, b} & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t. } & y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, m. \end{aligned} \tag{16}$$

7.2 对偶问题

同样使用拉格朗日乘子法，得到对偶问题：

$$\begin{aligned} \min_{\alpha} & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t. } & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m. \end{aligned} \tag{17}$$

比硬间隔只多了 $\alpha \leq C$ 的约束