

对偶坐标下降法 (DCDM) -L2R SVC

原问题

$$\min_w \frac{1}{2}w^T w + C \sum_{i=1}^l \xi(w; x_i, y_i) \quad (1)$$

其中 $\xi(w; x_i, y_i)$ 是损失函数，C是惩罚项，L1损失和L2损失的损失函数如下：

$$\max(1 - y_i w^T x_i, 0) \quad \text{and} \quad \max(1 - y_i w^T x_i, 0)^2 \quad (2)$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & f(\alpha) = \frac{1}{2} \alpha^T \bar{Q} \alpha - e^T \alpha \\ \text{subject to} \quad & 0 \leq \alpha_i \leq U, \forall i, \end{aligned}$$

其中， $\bar{Q} = Q + D$, D 是对角矩阵，并且 $Q_{ij} = y_i y_j x_i^T x_j$. 对于L1-SVC来讲 $U = C, D_{ii} = 0$ ，对于L2-SVC有 $U = \infty, D_{ii} = 1/2C$ ，

算法

DCDM共有两层循环，每一个外层循环 k 都要产生一个 α^k 向量；内层循环从1到 l （ α 的维度），一次只更新 α 的一个元素（ $\alpha^{k,i} \rightarrow \alpha^{k,i+1}$ ），固定其他元素。一次内层循环求解一个单变量的子问题。

$$\alpha^{k,i} = [\alpha_1^{k+1}, \dots, \alpha_{i-1}^{k+1}, \alpha_i^k, \dots, \alpha_l^k]^T, \quad \forall i = 2, \dots, l.$$

k 表示第 k 次外层循环， i 表示第 i 次内层循环。前 $i-1$ 个 α 的元素已经更新了之后，我们通过求解下面的单变量的子问题来实现 $\alpha^{k,i} \rightarrow \alpha^{k,i+1}$ 的更新：

$$\min_d f(\alpha^{k,i} + d e_i) \quad \text{subject to} \quad 0 \leq \alpha_i^k + d \leq U,$$

其中，

$$f(\alpha^{k,i} + d e_i) = \frac{1}{2} \bar{Q}_{ii} d^2 + \nabla_i f(\alpha^{k,i}) d + \text{constant},$$

$$e_i = [0, \dots, 0, 1, 0, \dots, 0]^T$$

下面，我们对这个二次函数进行求解：

令 $\Delta^P f(\alpha)$ 是投影梯度：

$$\nabla_i^P f(\alpha) = \begin{cases} \nabla_i f(\alpha) & \text{if } 0 < \alpha_i < U, \\ \min(0, \nabla_i f(\alpha)) & \text{if } \alpha_i = 0, \\ \max(0, \nabla_i f(\alpha)) & \text{if } \alpha_i = U. \end{cases}$$

容易得到，当 $\Delta^P f(\alpha) = 0$ 的时候我们不需要更新 $\alpha^{k,i}$ ，当 $\bar{Q}_{ii} > 0$ 的时候，二次函数的极值点为 $-\frac{\Delta_i f(\alpha^{k,i})}{\bar{Q}_{ii}}$ ，并且需要保证更新以后的 $\alpha^{k,i+1}$ 在约束范围内，所以有：

$$\alpha_i^{k,i+1} = \min \left(\max \left(\alpha_i^{k,i} - \frac{\nabla_i f(\alpha^{k,i})}{\bar{Q}_{ii}}, 0 \right), U \right).$$

因为在更新 $\alpha^{k,i+1}$ 的时候需要对 $\Delta_i f(\alpha^{k,i})$ 进行求解：

$$\nabla_i f(\alpha) = (\bar{Q}\alpha)_i - 1 = \sum_{j=1}^l \bar{Q}_{ij} \alpha_j - 1.$$

因为 \bar{Q}_{ii} 可能很大，计算的时候比较复杂，所以在线性SVM里面，我们可以重新定义 $\Delta_i f(\alpha^{k,i})$ 的求解过程：

因为：

$$\mathbf{w} = \sum_{j=1}^l y_j \alpha_j \mathbf{x}_j,$$

所以我们有：

$$\nabla_i f(\alpha) = y_i \mathbf{w}^T \mathbf{x}_i - 1 + D_{ii} \alpha_i.$$

参数 w 的更新规则：

$$\mathbf{w} \leftarrow \mathbf{w} + (\alpha_i - \bar{\alpha}_i) y_i \mathbf{x}_i.$$

并且我们可以初始化参数 $\alpha^0 = 0, w = 0$, 算法流程如下：

Algorithm 1 A dual coordinate descent method for Linear SVM

- Given α and the corresponding $w = \sum_i y_i \alpha_i x_i$.
- While α is not optimal

For $i = 1, \dots, l$

(a) $G = y_i w^T x_i - 1 + D_{ii} \alpha_i$

(b)

$$PG = \begin{cases} \min(G, 0) & \text{if } \alpha_i = 0, \\ \max(G, 0) & \text{if } \alpha_i = U, \\ G & \text{if } 0 < \alpha_i < U \end{cases}$$

(c) If $|PG| \neq 0$,

$$\bar{\alpha}_i \leftarrow \alpha_i$$

$$\alpha_i \leftarrow \min(\max(\alpha_i - G/\bar{Q}_{ii}, 0), U)$$

$$w \leftarrow w + (\alpha_i - \bar{\alpha}_i) y_i x_i$$

子问题的随机扰动

在算法1中，我们对 α 的更新是按照顺序进行元素的更新的，即 $\alpha_1, \alpha_2, \dots, \alpha_l$ ，但是实验证明，以一个打乱的随机顺序解决子问题可能会加快收敛速度。所以我们打乱 $\{1, \dots, l\} \rightarrow \{\pi(1), \dots, \pi(l)\}$ ，即按照 $\alpha_{\pi(1)}, \alpha_{\pi(2)}, \dots, \alpha_{\pi(l)}$ 的顺序去更新参数。

$$\alpha_t^{k,i+1} = \alpha_t^{k,i} + \arg \min_{0 \leq \alpha_t^{k,i} + d \leq U} f(\alpha^{k,i} + d e_t) \text{ if } \pi_k^{-1}(t) = i.$$

Shrinking 策略

因为 $0 \leq \alpha_i \leq U$ ，如果 $\alpha = 0$ 或者 $\alpha = U$ 的时候，那么 α 则可能保持不变。为了加快求解，我们进行Shrinking去求解下面的子问题：

$$\begin{aligned} \min_{\alpha_A} \quad & \frac{1}{2} \alpha_A^T \bar{Q}_{AA} \alpha_A + (\bar{Q}_{AA} \alpha_A - e_A)^T \alpha_A \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq U, i \in A \end{aligned}$$

其中，A是对应的active α 的集合， $\bar{A} = \{1, \dots, l\} / A$

shrinking 条件：

$$\alpha_i^{k,i} = 0 \text{ and } \nabla_i f(\boldsymbol{\alpha}^{k,i}) > \bar{M}^{k-1},$$

$$\alpha_i^{k,i} = U \text{ and } \nabla_i f(\boldsymbol{\alpha}^{k,i}) < \bar{m}^{k-1},$$

where

$$\bar{M}^{k-1} = \begin{cases} M^{k-1} & \text{if } M^{k-1} > 0, \\ \infty & \text{otherwise,} \end{cases}$$

$$\bar{m}^{k-1} = \begin{cases} m^{k-1} & \text{if } m^{k-1} < 0 \\ -\infty & \text{otherwise.} \end{cases}$$

$$M^{k-1} \equiv \max_j \nabla_j^P f(\boldsymbol{\alpha}^{k-1,j}), m^{k-1} \equiv \min_j \nabla_j^P f(\boldsymbol{\alpha}^{k-1,j}).$$

停止条件：

$$M^k - m^k < \epsilon$$

对偶坐标下降法（DCDM）-L2R LR

原问题

L2正则化逻辑回归目标是使以下函数最小化：

$$P^{\text{LR}}(\mathbf{w}) = C \sum_{i=1}^l \log \left(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i} \right) + \frac{1}{2} \mathbf{w}^T \mathbf{w},$$

对偶问题

$$\min_{\boldsymbol{\alpha}} D^{\text{LR}}(\boldsymbol{\alpha}) = \frac{1}{2} \boldsymbol{\alpha}^T Q \boldsymbol{\alpha} + \sum_{i:\alpha_i > 0} \alpha_i \log \alpha_i + \sum_{i:\alpha_i < C} (C - \alpha_i) \log(C - \alpha_i)$$

subject to $0 \leq \alpha_i \leq C, i = 1, \dots, l,$

其中 $Q_{ij} = y_i y_j \mathbf{x}_i^T \mathbf{x}_j$

求解此问题的单变量子问题：

$$\begin{aligned} \min_z \quad & g(z) \equiv (c_1 + z) \log(c_1 + z) + (c_2 - z) \log(c_2 - z) + \frac{a}{2} z^2 + bz \\ \text{subject to} \quad & -c_1 \leq z \leq c_2, \end{aligned}$$

where

$$c_1 = \alpha_i, c_2 = C - \alpha_i, a = Q_{ii}, \text{ and } b = (Q\alpha)_i.$$

其中 $\alpha^{k,i} \rightarrow \alpha^{k,i+1}$ 的更新为: $\alpha^{k,i+1} = \alpha^{k,i} + ze_i$

我们利用牛顿法对上述问题进行求解:

$$z^{k+1} = z^k + d, \quad d = -\frac{g'(z^k)}{g''(z^k)},$$

其中,

$$g'(z) = az + b + \log \frac{c_1 + z}{c_2 - z}, \text{ and } g''(z) = a + \frac{c_1 + c_2}{(c_1 + z)(c_2 - z)}.$$

同样的, 为了加速计算, 我们重写 $(Q\alpha)_i$:

因为:

$$\mathbf{w}(\alpha) \equiv \sum_{i=1}^l y_i \alpha_i \mathbf{x}_i.$$

所以我们有:

$$(Q\alpha)_i = \sum_{j=1}^l y_i y_j \alpha_j \mathbf{x}_j^T \mathbf{x}_i = y_i \left(\sum_{j=1}^l y_j \alpha_j \mathbf{x}_j^T \right) \mathbf{x}_i = y_i \mathbf{w}(\alpha)^T \mathbf{x}_i.$$

参数 \mathbf{w} 的更新规则:

$$\mathbf{w}(\alpha + ze_i) = \mathbf{w}(\alpha) + zy_i \mathbf{x}_i,$$